Matriz de costos y decisión de modelos: CRM Leads – Entrega Final

Precios consultados el 28/09/2026 (USD por 1 millón de tokens). Fuentes: página oficial de precios de OpenAI (developers.openai.com/api/docs/pricing) y tablas de referencia de precios de OpenAI y Anthropic actualizadas en septiembre de 2026. Los precios cambian sin aviso: verificalos en las páginas oficiales antes de presentar.

---

1. Precios de los modelos comparados

Modelo	Entrada	Salida	Batch API	Rol en esta matriz
OpenAI `gpt-5-nano`	$0.05	$0.40	−50 %	Tarea simple, alto volumen
OpenAI `gpt-5-mini`	$0.25	$2.00	−50 %	**Modelo actual del flujo**
OpenAI `gpt-5`	$1.25	$10.00	−50 %	Referencia de modelo grande
Claude Haiku 4.5	$1.00	$5.00	−50 %	Alternativa Anthropic económica
Claude Sonnet 5	$2.00	$10.00	−50 %	Lectura densa / redacción cuidada

2. Supuestos de consumo (por lead)

Concepto	Valor	Origen
Tokens de entrada	~600	Prompt de clasificación (~350) + mensaje del lead + formato del parser
Tokens de salida	~400	JSON con clasificación, razón y 2 borradores de respuesta
Proporción de leads VIP	20 %	Supuesto (ajustar con datos reales de Airtable)

> Son estimaciones. `gpt-5-mini` y `gpt-5-nano` son modelos de razonamiento y los tokens de razonamiento se cobran como salida, así que el consumo real puede ser mayor (con 1.200 tokens de salida, el costo de `gpt-5-mini` pasa de $0.95 a $2.55 por 1.000 leads). **Reemplazá estos supuestos con los tokens**

reales que muestra el panel de uso de OpenAI o el historial de ejecuciones de n8n.

---

3. Matriz de decisión por tarea

Tarea A: clasificar el lead y redactar los dos borradores (todos los leads)

Modelo	Costo / 1.000 leads	vs. modelo actual	Evaluación
`gpt-5-nano`	**$0.19**	−80 %	Suficiente para clasificación binaria; validar calidad de los borradores
`gpt-5-mini` (actual)	**$0.95**	—	Buen equilibrio; sigue instrucciones y devuelve JSON estructurado de forma confiable
Claude Haiku 4.5	$2.60	+174 %	Más caro sin ventaja para mensajes cortos
`gpt-5`	$4.75	+400 %	Sobredimensionado para una clasificación de dos categorías
Claude Sonnet 5	$5.20	+447 %	Sobredimensionado para esta tarea

Decisión: `gpt-5-mini`. Los mensajes de los leads son cortos y la clasificación es binaria (VIP/Normal), por lo que no se justifica un modelo grande ni uno de "lectura densa". Ahorro frente a usar `gpt-5` para todo: **80 %** ($4.75 → $0.95 por 1.000 leads). **Mejora propuesta:** probar `gpt-5-nano` con los casos de prueba del flujo; si clasifica igual de bien, el ahorro adicional es otro 80 %.

Tarea B: redacción de la respuesta a leads VIP (propuesta, no implementada)

Supuesto: 200 de cada 1.000 leads son VIP, ~700 tokens de entrada y ~250 de salida por llamada extra.

Modelo	Costo / 200 leads VIP	Evaluación
`gpt-5-mini`	$0.14	Suficiente si los borradores actuales ya aprueban

Claude Sonnet 5	$0.78	Mejor redacción para el cliente de más valor

Decisión: mantener `gpt-5-mini` (los borradores pasan por revisión humana antes de enviarse, así que el humano corrige el tono si hace falta). Si el negocio quisiera un tono más pulido, Sonnet 5 **solo para VIP** costaría ~$0.64 extra por cada 1.000 leads, porque se usa solo en el 20 % de los casos.

Tarea C: procesamiento masivo (ej. reclasificar 10.000 leads históricos)

Modo	`gpt-5-mini`	`gpt-5-nano`
Tiempo real	$9.50	$1.90
Batch API (resultado en hasta 24 h)	**$4.75**	**$0.95**

Decisión: para cargas masivas no urgentes usar **Batch API**: ahorro fijo del **50 %**. Para el flujo en vivo (un lead a la vez, con respuesta rápida) el tiempo real es necesario.

---

4. Otras optimizaciones ya presentes en el flujo

Medida	Dónde está	Efecto sobre el costo
Trigger por Webhook (no polling)	`Recibir formulario Tally`	Solo se ejecuta cuando hay un lead nuevo
Validación antes de la IA	`Validar datos completos`	Los datos incompletos nunca consumen tokens
Una sola llamada a la IA por lead	`Clasificar lead con IA`	Clasificación + 2 borradores en un mismo prompt
Límite de tokens de salida	`OpenAI Chat Model` (`maxTokens: 2000`)	Tope de gasto por llamada
Modelo económico	`gpt-5-mini`	~80 % menos que un modelo grande
Rama Normal sin aprobación humana	`Separar VIP y Normal`	Sin costo de tiempo humano en leads simples

5. Resumen del ahorro estimado

Comparación	Ahorro
`gpt-5-mini` vs. `gpt-5` en todos los leads	**80 %**
Mejora posible: `gpt-5-nano` vs. `gpt-5-mini`	80 % adicional
Batch API vs. tiempo real (cargas masivas)	**50 %**
Sonnet 5 solo en VIP vs. Sonnet 5 en todos	80 % (ya que solo el 20 % de leads lo usa)

Costo estimado del sistema actual: ~$0.95 por cada 1.000 leads (hasta ~2.55 si el razonamiento consume más tokens de salida). Verificar con datos reales antes de la entrega.